

Análisis de Caso

Análisis Exploratorio de Datos 🧑

Elaborado por:
Yarimar Fragoza

Introducción

El análisis exploratorio de datos, conocido como EDA por sus siglas en inglés (*Exploratory Data Analysis*), es una etapa inicial del trabajo con datos que permite conocer mejor un conjunto de información antes de aplicar modelos, análisis complejos o visualizaciones avanzadas. Su propósito principal es observar cómo están organizados los datos, identificar patrones, detectar errores, valores atípicos, relaciones entre variables y posibles problemas de calidad.

En el caso de InfoRetail, el EDA resulta especialmente importante porque la empresa trabajará con información de ventas, productos, sucursales y clientes. Antes de tomar decisiones o construir reportes, es necesario comprender qué contiene el dataset y qué técnicas pueden ayudar a interpretarlo mejor. La guía justamente pide elaborar una propuesta clara para orientar ese trabajo inicial.

1. Diferencia entre EDA e IDA

Aunque a veces se parecen, el EDA y el IDA no son exactamente lo mismo. El **IDA** o análisis inicial de datos se enfoca en una primera revisión general del dataset. En esta etapa se suele revisar la estructura de los datos, los nombres de columnas, los tipos de variables, la cantidad de registros y la presencia de valores nulos o inconsistencias básicas. Es decir, el IDA sirve para tener una visión preliminar del contenido.

Por otro lado, el **EDA** va un poco más allá. No solo busca revisar la estructura, sino también entender el comportamiento de los datos. En esta etapa se analizan distribuciones, relaciones entre variables, posibles patrones, valores extremos y tendencias que pueden ser importantes para el análisis posterior. En palabras simples, el IDA sería la primera inspección y el EDA sería una exploración más profunda para descubrir qué nos dicen realmente los datos.

2. Tres técnicas de EDA y qué permiten observar

1. Histograma

El histograma es una técnica que permite observar la distribución de una variable numérica. Sirve para ver con qué frecuencia aparecen ciertos valores dentro de un rango. Por ejemplo, en un dataset de ventas, podría utilizarse para analizar cómo se distribuyen los montos vendidos.

Esta técnica ayuda a detectar si los datos están concentrados en ciertos valores, si existe dispersión, si la distribución es simétrica o si hay sesgos. También puede dar pistas sobre la presencia de valores atípicos o sobre si una variable tiene una forma de distribución normal o irregular.

2. Boxplot

El boxplot, o diagrama de caja, permite resumir gráficamente la distribución de una variable numérica a través de la mediana, los cuartiles y los valores extremos. Es muy útil para detectar **outliers**, es decir, datos que se alejan demasiado del comportamiento general.

Por ejemplo, si InfoRetail analiza los montos de compra por cliente, el boxplot podría mostrar si existen clientes con compras muchísimo más altas que el resto. Esta técnica también facilita comparar distribuciones entre grupos, como sucursales o categorías de producto.

3. Matriz de correlación

La matriz de correlación sirve para medir la relación entre variables numéricas. Permite identificar si dos variables tienden a moverse juntas, ya sea de manera positiva, negativa o si prácticamente no existe relación entre ellas.

En un contexto como el de InfoRetail, podría servir para analizar si existe relación entre cantidad de productos vendidos y monto total de ventas, o entre frecuencia de compra y gasto total del cliente. Esta técnica es útil porque ayuda a descubrir relaciones que luego pueden ser importantes en modelos predictivos o en decisiones del negocio.

3. Dos herramientas que podrían usarse

1. Python con pandas y seaborn

Python es una de las herramientas más utilizadas en análisis de datos. Con librerías como `pandas`, se puede cargar, limpiar y manipular información de forma muy flexible. Además, con librerías como `seaborn` o `matplotlib`, se pueden crear gráficos exploratorios de manera relativamente sencilla.

Una de sus principales ventajas es que permite automatizar procesos, trabajar con grandes volúmenes de datos y combinar exploración, transformación y análisis en un mismo entorno. También es muy útil cuando el proyecto crecerá en complejidad y luego se necesitarán modelos de machine learning.

2. Excel

Excel también puede ser una herramienta útil para aplicar técnicas exploratorias básicas, sobre todo cuando se trabaja con datasets pequeños o medianos. Permite ordenar, filtrar, resumir datos y generar tablas o gráficos de manera rápida y visual.

Su principal ventaja es que muchas personas ya lo conocen, por lo que resulta accesible para equipos que no tienen formación técnica avanzada. Además, es práctico para revisiones rápidas y para presentar resultados iniciales de forma sencilla.

4. Conclusión

Realizar un análisis exploratorio de datos antes de cualquier análisis complejo es fundamental porque permite comprender mejor la información con la que se va a trabajar. Gracias al EDA, es posible detectar errores, identificar patrones, reconocer relaciones entre variables y encontrar valores atípicos que podrían afectar los resultados.

En otras palabras, el EDA ayuda a tomar decisiones más informadas desde el inicio y reduce el riesgo de hacer interpretaciones incorrectas. En el caso de InfoRetail, aplicar estas técnicas desde el comienzo permitiría al equipo conocer mejor su dataset y establecer una base sólida para futuros análisis, reportes o modelos más avanzados. La actividad justamente apunta a eso: orientar el trabajo inicial del equipo con una propuesta teórica clara.