

Análisis de Caso

L1  Fundamentos del Aprendizaje de Máquina

Elaborado por:
Yarimar Fragoza

Introducción

En este caso, la empresa DataSolutions S.A. necesita resolver distintos problemas de negocio mediante aprendizaje de máquina. Para ello, es importante identificar correctamente el tipo de problema, seleccionar el modelo más adecuado, considerar los riesgos asociados y proponer un flujo de trabajo ordenado para su implementación.

1. Clasificación de cada problema

Problema A: Predecir el monto de ventas semanales de una cadena de supermercados

Este problema corresponde a una tarea de **regresión**, porque el objetivo es predecir un valor numérico continuo, en este caso el monto de ventas semanales.

Problema B: Detectar si un cliente abandonará un servicio de streaming

Este problema corresponde a una tarea de **clasificación**, porque la salida esperada es una categoría: por ejemplo, “abandona” o “no abandona” el servicio.

Problema C: Agrupar a los clientes bancarios por comportamiento de gasto sin tener etiquetas

Este problema corresponde a una tarea de **aprendizaje no supervisado**, específicamente de agrupamiento o clustering, porque no existen etiquetas previas y se busca identificar grupos con comportamientos similares.

2. Selección de modelo y justificación

Problema A: Predicción de ventas semanales

Para este caso, un modelo adecuado es la **regresión lineal**.

Justificación:

La regresión lineal es útil cuando se quiere estimar una variable numérica a partir de otras variables, como promociones, estacionalidad, número de clientes, días festivos o historial de ventas. Es un modelo sencillo, fácil de interpretar y permite entender cómo influyen las variables en el resultado.

Ventajas:

- Es fácil de implementar.
- Sus resultados son interpretables.
- Funciona bien cuando existe una relación aproximadamente lineal entre las variables.

Limitaciones:

- Puede no capturar relaciones complejas.
- Es sensible a valores atípicos.
- Su desempeño baja si la relación entre variables no es lineal.

Problema B: Detección de abandono de clientes

Para este caso, un modelo adecuado es el **árbol de decisión**.

Justificación:

El árbol de decisión permite clasificar si un cliente abandonará o no el servicio según variables como frecuencia de uso, tiempo de suscripción, tipo de plan o cantidad de reclamos. Es útil porque genera reglas fáciles de interpretar para el negocio.

Ventajas:

- Es fácil de entender y explicar.
- Maneja bien variables numéricas y categóricas.
- Permite identificar factores importantes en la decisión.

Limitaciones:

- Puede sobreajustarse si el árbol crece demasiado.
- A veces no generaliza bien con datos nuevos.
- Puede ser inestable si cambian ligeramente los datos.

Problema C: Segmentación de clientes bancarios

Para este caso, un modelo adecuado es **K-means**.

Justificación:

K-means es apropiado para agrupar clientes con características similares de gasto, ingresos, frecuencia de compras o uso de productos financieros. Al no haber etiquetas, este algoritmo ayuda a descubrir patrones ocultos en los datos.

Ventajas:

- Es simple y rápido.
- Es útil para segmentación de clientes.
- Facilita encontrar grupos con comportamientos parecidos.

Limitaciones:

- Se debe definir previamente el número de grupos.
- Puede verse afectado por valores atípicos.
- Funciona mejor cuando los grupos tienen formas relativamente compactas y separadas.

3. Riesgos y desafíos

Problema A: Regresión de ventas

Uno de los principales riesgos es que los datos históricos no reflejen cambios futuros del mercado, como inflación, cambios de precios o nuevas campañas. También puede haber variables importantes no incluidas en el modelo. Otro desafío es el **overfitting**, si el modelo aprende demasiado bien los datos pasados y luego falla al predecir nuevos casos.

Problema B: Clasificación de abandono

Un desafío frecuente es el **desbalance de clases**, ya que normalmente habrá muchos más clientes que permanecen que clientes que abandonan. Esto puede llevar a que el modelo prediga casi siempre la clase mayoritaria. También existe riesgo de sobreajuste y de usar variables poco relevantes o redundantes.

Problema C: Segmentación de clientes

En este caso puede aparecer la **maldición de la dimensionalidad**, ya que si hay muchas variables el agrupamiento puede perder efectividad. También puede ser difícil interpretar los grupos obtenidos y decidir cuántos clústeres son realmente útiles. Además, si los datos no están bien normalizados, algunas variables podrían influir más que otras sin justificación.

4. Diseño del flujo de trabajo

Voy a diseñar el flujo de trabajo para el **Problema B: detectar si un cliente abandonará un servicio de streaming**, ya que es un caso muy común de clasificación en negocios. La actividad pide mostrar etapas como preparación de datos, selección del modelo, entrenamiento, evaluación y despliegue.

Esquema del flujo de trabajo

1. Definición del problema

Determinar que el objetivo es predecir si un cliente abandonará o no el servicio.

2. Recolección de datos

Obtener datos de uso de la plataforma, historial de pagos, tiempo de permanencia, tipo de plan, reclamos, frecuencia de visualización, entre otros.

3. Preparación de datos

Limpiar datos faltantes, eliminar duplicados, transformar variables categóricas y seleccionar las variables más relevantes.

4. División del conjunto de datos

Separar los datos en entrenamiento y prueba.

5. Selección del modelo

Elegir un árbol de decisión por su interpretabilidad.

6. Entrenamiento del modelo

Ajustar el modelo con los datos de entrenamiento.

7. Evaluación del modelo

Medir el desempeño con datos de prueba.

8. Ajuste y mejora

Corregir problemas de sobreajuste, ajustar hiperparámetros y revisar variables.

9. Despliegue

Implementar el modelo en un sistema que ayude a identificar clientes con riesgo de abandono.

10. Monitoreo

Revisar periódicamente el rendimiento del modelo y actualizarlo si cambian los patrones de los clientes. Esquema visual:

Definición del problema → Recolección de datos → Preparación de datos → División train/test → Selección del modelo → Entrenamiento → Evaluación → Ajuste → Despliegue → Monitoreo

5. Métricas de evaluación

Como la actividad dice que esto es opcional, igual conviene agregarlo porque suma.

- **Problema A (Regresión):** MAE, MSE o RMSE.
- **Problema B (Clasificación):** accuracy, precision, recall y F1-score.
- **Problema C (Clustering):** índice de silueta o evaluación de separación entre grupos.

6. Reflexión personal

Este caso me permitió comprender que en aprendizaje de máquina no basta con conocer algoritmos, sino que primero hay que entender bien el problema de negocio. Aprendí que la elección del modelo depende del tipo de dato que queremos predecir y del objetivo del análisis. También entendí que cada modelo tiene ventajas, pero también limitaciones y riesgos que deben considerarse antes de implementarlo. En la práctica, un buen resultado no depende solo del algoritmo, sino también de la calidad de los datos, la preparación previa y la evaluación adecuada del modelo.